

# Uczenie ze wzmocnieniem

Marcin Pluciński

`mplucinski@wi.zut.edu.pl`

# Uczenie ze wzmocnieniem – ćwiczenia nr 3

# Uczenie ze wzmocnieniem – zadanie 1

- Przedmiotem rozważań będzie **gra w zapałki**.
- Mamy do dyspozycji pewną ilość  $N$  zapałek.
- W grze bierze udział dwóch graczy, którzy na przemian zabierają 1 lub 2 zapałki.
- Przegrywa ten gracz, który zabiera zapałki jako ostatni.

Należy wyznaczyć optymalną strategię gry stosując uczenie ze wzmocnieniem za pomocą algorytmu Q-learning (dla uproszczenia możemy założyć, że nasz przeciwnik będzie grał w sposób losowy).

# Uczenie ze wzmocnieniem – zadanie 2

- Przedmiotem rozważań będzie gra w ruletkę.
- Będziemy obstawiać wielokrotności 1 zł na kolor – prawdopodobieństwo wygranej wynosi więc  $p = \frac{18}{37}$ .
- Wyznacz optymalną strategię obstawiania stosując uczenie ze wzmocnieniem, tak by wygrać więcej niż 100 zł.
- Sporządź wykres optymalnej funkcji wartości.

---

Założenia:

- Stan  $x$  określa kapitał gracza w pełnych zł:  $x \in \{0, 1, 2, 3, \dots\}$ .
- Możliwe do wykonania akcje (obstawienia) w stanie  $x$ :  $a \in \{1, \dots, x\}$ .

# Uczenie ze wzmocnieniem – zadanie 3

- Zaprojektuj dwuwymiarowe środowisko komórkowe o wymiarach  $10 \times 10$ . Podobne środowisko, ale o mniejszym wymiarze analizowane było na pierwszych laboratoriach.
- Rozmieść przeszkody tak, by zajmowały ok. 20% komórek.
- Podobnie jak na prostszym przykładzie pokazanym na kolejnym slajdzie, złożmy że po osiągnięciu lewego-górnego rogu otrzymamy wzmocnienie równe 0.5, a po osiągnięciu prawego-górnego rogu otrzymamy wzmocnienie równe 1. Stany w tych rogach są absorbujące. Przejścia do pozostałych stanów skutkują wzmocnieniem równym 0.
- Przyjmij epizodyczny tryb uczenia się, przy czym po osiągnięciu stanu absorbującego, nowy stan początkowy powinien być wybierany losowo.
- Zaimplementuj symulator swojego środowiska oraz znajdź optymalną strategię poruszania się w nim. Uczenie zrealizuj z wykorzystaniem algorytmu Q-learning z eksploracją wykorzystującą strategię  $\epsilon$ -zachłanną.

# Procesy decyzyjne Markowa

$j$					
4	0.5	0	0	0	1
3	0	0	0	0	0
2	0				0
1	0	0	0		0
0	0	0	0	0	0
	0	1	2	3	4
	$i$				

- Proces jest deterministyczny.
- Stany:  $X = \{(i, j)\}$ ,  $i, j = 0 \dots 4$
- Akcje:  $A = \{\uparrow, \downarrow, \leftarrow, \rightarrow\}$
- Stany  $(0, 4)$  i  $(4, 4)$  są absorbujące – wykonanie dowolnej akcji nie zmienia stanu.

Funkcja wzmocnień:

$$\rho((i, j), a) = \begin{cases} 1 & \text{gdy } x = (3, 4) \text{ i } a = \rightarrow \\ 1 & \text{gdy } x = (4, 3) \text{ i } a = \uparrow \\ 0.5 & \text{gdy } x = (0, 3) \text{ i } a = \uparrow \\ 0.5 & \text{gdy } x = (1, 4) \text{ i } a = \leftarrow \\ 0 & \text{w innych przypadkach.} \end{cases}$$

Funkcje przejścia dla pozostałych stanów:

$$\begin{aligned} \delta((i, j), \uparrow) &= (i, \text{if dozwolone}(j+1) : j+1 \text{ else : } j) \\ \delta((i, j), \downarrow) &= (i, \text{if dozwolone}(j-1) : j-1 \text{ else : } j) \\ \delta((i, j), \leftarrow) &= (\text{if dozwolone}(i-1) : i-1 \text{ else : } i, j) \\ \delta((i, j), \rightarrow) &= (\text{if dozwolone}(i+1) : i+1 \text{ else : } i, j) \end{aligned}$$